

Annexe 2 : Conception d'un agent RPA **autonome pour l'extraction documentaire** **(Projet Doc-Sat)**

1. Contexte technique et contraintes métier	2
2. Architecture de la solution	2
A. Vérifications de départ et gestion des droits	2
B. Mode autonome et configuration	3
C. Moteur RPA, résilience et fichiers composites	4
D. Maintenance disque et Audit de production	5
3. Preuves matérielles	6
4. Bilan	11

1. Contexte technique et contraintes métier

Le projet "**Doc-Sat dématérialisés**" vise à rendre les documents techniques accessibles aux techniciens sur le terrain, directement depuis leurs tablettes. Cependant, l'interface du logiciel intranet actuel n'est pas adaptée à cet usage mobile. Comme ce logiciel est géré au niveau national, attendre une mise à jour officielle aurait pris beaucoup trop de temps (malgré nos demandes). J'ai donc été chargé de développer un programme **RPA** en **Python** pour récupérer ces **PDF** nous-mêmes. Le programme tourne tous les soirs pour télécharger une liste prédéfinie de documents. Il les centralise ensuite sur l'espace commun Atlas.

2. Architecture de la solution

J'ai structuré le code pour qu'il fonctionne comme un vrai service autonome et pas seulement comme un petit script.

A. Vérifications de départ et gestion des droits

Le problème majeur avec **Documentum**, c'est qu'il force l'ouverture physique de chaque **PDF** téléchargé. Lors d'un téléchargement en masse, des centaines de fenêtres s'ouvrent, ce qui fait saturer l'ordinateur. Le programme doit donc pouvoir interagir avec le lecteur **PDF** du système pour fermer ces fenêtres en arrière-plan.

Pour garder un code simple à maintenir, j'ai choisi de ne coder la gestion que pour un seul logiciel : **Adobe Acrobat**. Avant le lancement des opérations, le script sécurise son environnement d'exécution :

- J'ai utilisé la bibliothèque "**winreg**" pour interagir avec le registre **Windows**. Mon but était de modifier le programme par défaut pour ouvrir les **PDF**, mais comme je n'avais pas les permissions administrateur, je n'ai pu que le lire.

- Le programme vérifie donc si **Adobe Acrobat** est bien le lecteur par défaut. Si ce n'est pas le cas, il s'arrête et affiche un tutoriel pour que l'utilisateur le mette par défaut lui-même. Je ne voulais pas coder la gestion de chaque lecteur **PDF** au cas par cas, donc j'ai fait ce choix pour garder un code simple
- J'ai aussi mis en place un système d'arrêt d'urgence. J'ai utilisé un *listener* asynchrone avec "**pynput**" pour surveiller le clavier. Si l'utilisateur fait "**Ctrl+Shift+Q**", le programme s'arrête instantanément.

B. Mode autonome et configuration

Le programme est conçu pour s'auto-gérer en cas de planification nocturne.

- J'ai utilisé une version de **Chrome** portable (*for Testing*) pour isoler mon script du navigateur par défaut. Je l'ai aussi configuré en mode "*headless*" (sans interface graphique). Le programme tourne en fond de manière transparente. Comme ça, il n'interfère pas avec l'affichage et reste indépendant de l'**OS**.
- Le programme utilise la fonction "*inputtimeout*" lors du démarrage. S'il possède déjà une configuration valide, il demandera à l'utilisateur s'il souhaite modifier les paramètres actuels et lui laissera un délai de **10 secondes**. S'il n'y a pas de réponse, le programme considère cela comme un non et bascule automatiquement en mode exécution.
- J'ai isolé les données sensibles (**NNI**, mot de passe) et les chemins de répertoires dans un fichier "**config.json**" (créé automatiquement) à la racine du programme. Cela permet à l'utilisateur de modifier ses répertoires ou ses identifiants directement, sans avoir à toucher au code **Python**.

- Lors de la configuration, on demande à l'utilisateur d'entrer un chemin pour un dossier ou un fichier. La validation des choix de configuration est complexe. Le programme exécute une série de tests (vérification des droits d'accès, syntaxe Windows **winerror 123**, détection d'archives Excel corrompues **BadZipFile**). Comme ça, il détermine la cause exacte de l'erreur et l'explique clairement à l'utilisateur avant de lancer le navigateur.
- Le script analyse aussi les réponses de l'utilisateur avec la méthode **set()** pour regrouper les mots-clés (ex: **"OUI"**, **"YES"**, **"Y"**). Il prend également en compte les conflits : si l'utilisateur écrit **"OUI"** et **"NON"** dans la même phrase, le programme renvoie un message d'ambiguïté.

C. Moteur RPA, résilience et fichiers composites

L'interface de Documentum était instable. J'ai donc dû intégrer plusieurs sécurités au pilotage **Selenium**.

- Le programme commence par lire les fichiers Excel avec **"openpyxl"** pour extraire les *hyperliens*. Il applique ensuite la méthode **set()** pour ignorer les liens redondants. Comme ça, il supprime les doublons et optimise le traitement.
- J'ai créé une méthode **"resilient_action"** pour encapsuler chaque clic ou saisie. Elle fait des tentatives (*retry*) pour intercepter les exceptions, principalement **"StaleElementReferenceException"**
- Le script gère aussi les ralentissements réseau. Il détecte les barres de progression de téléchargement (**percent**). Il force une mise en attente jusqu'à leur disparition (**staleness_of**) pendant un maximum de **120 secondes**, pour éviter de corrompre le fichier.

- J'ai dû coder une logique spécifique pour les fichiers composites. Le programme identifie ces fichiers dynamiquement, puis il descend dans les **"iframes"** (**view** -> **workarea** -> **content**) et navigue dans les menus contextuels pour faire le téléchargement.
- Enfin, pour éviter la saturation de la mémoire, le programme force régulièrement la fermeture d'**Adobe** en arrière-plan (**taskkill**). Le problème, c'est que cette fermeture brutale se désynchronise parfois avec **Documentum** et génère des pop-up d'erreur **Adobe** qui bloquent le processus. J'ai donc utilisé la bibliothèque **"ctypes"** de l'**API Win32**. Le script détecte ces boîtes de dialogue et envoie des messages de bas niveau (**WM_CLOSE**, **WM_DESTROY**) pour les fermer proprement en arrière-plan sans gêner l'utilisateur.
- Le programme gère les permissions métier dynamiquement. Il lit le code **HTML** et s'il détecte le texte **"droits suffisants"**, il classe le document en **"Refusé"** et passe au suivant sans arrêter l'exécution.

D. Maintenance disque et Audit de production

Pour garder un espace propre, le programme gère le cycle de vie des données.

- À chaque lancement, il purge le dossier temporaire de **Documentum**. Il déplace les nouvelles archives et sauvegarde les anciens exports dans un dossier de backup.
- En fin de processus, il injecte un résumé statistique précis dans les logs (console et fichier texte). Il détaille le total traité, les succès, les refus liés aux permissions, et les erreurs techniques.

- Pour vérifier la cohérence, le programme compare mathématiquement le nombre de liens uniques scannés au nombre de fichiers **PDF** physiquement présents. Toute différence déclenche une alerte pour signaler des fichiers manquants ou des doublons.
- L'**OS** verrouille les **PDF** téléchargés en lecture. Lors du transfert de fichier, le programme utilise *os.chmod* pour forcer **Windows** à libérer le fichier avant de le déplacer.

3. Preuves matérielles

Fonction de résilience :

```
def resilient_action(driver, by, value, action="click", text=None, timeout=30):
    wait = wait_x(driver, timeout)
    locator = (by, value)

    for i in range(50):
        try:
            if action == "text":
                return wait.until(EC.visibility_of_element_located(locator)).text.strip()
            elif action == "click":
                wait.until(EC.element_to_be_clickable(locator)).click()
                return True
            elif action == "send_keys":
                elem = wait.until(EC.element_to_be_clickable(locator))
                elem.clear()
                elem.send_keys(text)
                return True
        except (StaleElementReferenceException,
                TimeoutException,
                ElementNotInteractableException,
                ElementClickInterceptedException) as e:
            if i == 49:
                raise e
            time.sleep(0.5)
    return None
```

Adaptation si le téléchargement prend trop de temps :

```
except (TimeoutException, StaleElementReferenceException, WebDriverException) as e:
    # Gestion des erreurs et retry
    try:
        dlBars = driver.find_elements(By.NAME, "percent")
        if len(dlBars) > 0:
            WebDriverWait(driver, 120).until(EC.staleness_of(dlBars[0]))
            continue
    except TimeoutException:
        pass

    errorName = type(e).__name__
    print(f"Erreur {errorName} : Tentative {attempt + 1}/30")
    cleanErrorPopup(driver)
    attempt += 1
    time.sleep(10)
    if attempt < 30:
        driver.refresh()
    continue
```

Figure 1 : Implémentation du pattern de résilience et d'asynchronisme.

Fonction qui gère la fermeture d'**Adobe**, et des pop-up si nécessaire :

```
def killAdobe():
    ....adobeLilFriends = ["Acrobat.exe", "AcroRd32.exe", "AcroCEF.exe"]
    ....
    ....for process in adobeLilFriends:
    ....    try:
    ....        subprocess.call(
    ....            ["taskkill", "/f", "/t", "/im", process],
    ....            stdout=subprocess.DEVNULL,
    ....            stderr=subprocess.DEVNULL)
    ....    except Exception:
    ....        pass
    ....
    ....    try:
    ....        EnumWindows = ctypes.windll.user32.EnumWindows
    ....        GetClassName = ctypes.windll.user32.GetClassNameW
    ....        GetWindowText = ctypes.windll.user32.GetWindowTextW
    ....        PostMessage = ctypes.windll.user32.PostMessageW
    ....
    ....        # Signaux de destruction
    ....        WM_CLOSE = 0x0010 # Demande de fermeture
    ....        WM_QUIT = 0x0012 # Ordre de quitter le thread
    ....        WM_DESTROY = 0x0002 # Ordre de destruction mémoire
    ....
    ....        def foreach_window(hwnd, lParam):
    ....            cls = ctypes.create_unicode_buffer(256)
    ....            GetClassName(hwnd, cls, 256)
    ....
    ....            # #32770 = Boîte de dialogue windows
    ....            if cls.value == "#32770":
    ....                title = ctypes.create_unicode_buffer(256)
    ....                GetWindowText(hwnd, title, 256)
    ....
    ....                # Si le titre contient "acro"
    ....                if "acro" in title.value.lower():
    ....                    PostMessage(hwnd, WM_CLOSE, 0, 0)
    ....                    PostMessage(hwnd, WM_QUIT, 0, 0)
    ....                    PostMessage(hwnd, WM_DESTROY, 0, 0)
    ....                return True
    ....
    ....        # Scan global
    ....        EnumWindows(ctypes.WINFUNCTYPE(ctypes.c_bool, ctypes.c_int, ctypes.c_int)(foreach_window), 0)
    ....
    ....    except Exception:
    ....        pass
```

Figure 2 : Pilotage système et fermeture propre

Logs final une fois les tâches terminé (elle est aussi affiché dans la console) :

```
2026-06-26 12:36:31 | INFO      |
=====
RÉSUMÉ DES OPÉRATIONS
=====
Total des cas traités : 1024

SUCCÈS : 929
> Fichiers normaux      : 870
> Fichiers composites   : 59

REFUS (Permissions) : 95
> Refus globaux        : 95
> Refus composites     : 0

ERREURS TECHNIQUES : 0
> Erreurs normales     : 0
> Erreurs composites   : 0
> Erreurs fatales      : 0

DURÉE : 1:34:46
=====
2026-06-26 12:36:34 | INFO      | ALERTE : Il manque 95 fichier(s). Consultez les logs.
```

Figure 3 : Rapport d'audit de production.

Méthode qui gère le choix que l'utilisateur a envoyé :

```
def choixOuiNon(phrase_brute: str) -> str:
    if not phrase_brute or not phrase_brute.strip():
        return "VIDE"

    mots_utilisateurs = set(phrase_brute.strip().upper().split())

    oui = {"YES", "OUI", "OUAI", "OUEP", "SURE", "Y", "YE", "O", "OU", "W", "WI"}
    non = {"NON", "NOP", "NAH", "NADA", "NUH", "NOPE", "N", "NO", "NA", "NU"}

    contient_oui = bool(mots_utilisateurs & oui)
    contient_non = bool(mots_utilisateurs & non)

    if contient_oui and contient_non:
        return "CONFLIT" # Conflit
    elif contient_oui:
        return "OUI"
    elif contient_non:
        return "NON"
    else:
        return "NONE"
```

Méthode qui gère le chemin du fichier **Excel** que l'utilisateur a envoyé :

```
def checkExcelFile(chemin) -> str:
    ....
    if not chemin or not chemin.strip():
        ....
        return "VIDE"
    ....
    chemin_propre = chemin.strip()

    ....
    try:
        ....
        os.stat(chemin_propre)
    ....
    except FileNotFoundError:
        ....
        return "INEXISTANT"

    ....
    except PermissionError:
        ....
        return "BLOQUE"

    ....
    except OSError as e:
        ....
        if getattr(e, 'winerror', None) == 123:
            ....
            return "INVALIDE"
        ....
        else:
            ....
            print(f"Erreur système critique inattendue : {e}")
            ....
            return "ERREUR_FATALE"

    ....
    if not os.path.isfile(chemin_propre):
        ....
        return "PAS_FICHER"
    ....

    ....
    if not chemin_propre.lower().endswith(('.xlsx', '.xlsm')):
        ....
        return "MAUVAIS_FORMAT"
    ....

    ....
    try:
        ....
        wbTemp = openpyxl.load_workbook(chemin_propre, read_only=True)
        ....
        wbTemp.close()
        ....
        return "EXCEL_VALIDE"
    ....
    except (BadZipFile, InvalidFileException):
        ....
        return "FICHER_CORROMPU"

    ....
    except Exception as e:
        ....
        print(f"Erreur inconnue lors de la lecture du fichier Excel : {e}")
        ....
        return "ERREUR_AUTRE"
```

Figure 4 : Sécurisation des entrées utilisateur et gestion des exceptions système.

Une partie de la boucle qui gère le changement en mode écriture et déplacement des fichiers :

```
# %% Déplacement des fichier de "Viewed" (Documentum) jusqu'au dossier "PDF Export"
file_names = os.listdir(documentum_path)
total_fichiers = len(file_names)
fichiers_deplaces = 0

timeout_os = 20
start_time = time.time()

while len(file_names) > 0 and (time.time() - start_time) < timeout_os:

    for file_name in file_names[:]:
        src_path = os.path.join(documentum_path, file_name)
        dst_path = os.path.join(target_dir, file_name)

        try:
            os.chmod(src_path, stat.S_IWRITE)
            shutil.move(src_path, dst_path)

            file_names.remove(file_name)
            fichiers_deplaces += 1
            print(f"Le fichier {file_name} a été récupéré avec succès.")

        except PermissionError:
            pass

        except FileNotFoundError:
            file_names.remove(file_name)
```

Figure 5 : Manipulation des droits OS pour le déverrouillage des fichiers.

4. Bilan

J'ai pu déployer une solution logicielle robuste. J'ai développé une architecture tolérante aux pannes avec les *retry*, la déduplication et les validations mathématiques. J'ai aussi fait en sorte qu'elle soit respectueuse de l'écosystème **Windows** avec l'**API Win32** et le mode *headless*. J'ai ainsi livré un outil de production autonome qui permet d'assurer la disponibilité des documents pour le projet de **Doc-Sat dématérialisé**.